

PORTAL B2B RETAIL

Campo	Información
Título	Portal B2B Retail - Documento de Diseño (Entrega 1, versión corregida)
Grupo	EKS
Integrantes	Sara Lopez Marin / Luis Alejandro Castrillon Pulgarin
Endpoint central	POST /ordenes-compra/{id}/confirmación
Fecha de esta versión	11/09/2026

1. Glosario del dominio

Términos usados a lo largo del documento, en el orden en que resultan más relevantes para entender el flujo de confirmación de órdenes.

Término	Definición
OTIF	On-Time In-Full. Indicador que mide el porcentaje de órdenes entregadas completas y a tiempo, respecto del total de órdenes confirmadas en el periodo.
Fill Rate	Porcentaje de unidades o líneas de una orden que se despachan efectivamente frente a lo solicitado por el proveedor, sin contar faltantes.
CEDI	Centro de Distribución. Instalación física donde se descargan los productos de los proveedores; tiene franjas horarias de descarga con capacidad finita.
Franja CEDI	Bloque de tiempo (por ejemplo, de 1 hora) en un CEDI, con un cupo máximo de camiones/proveedores que pueden descargar en simultáneo.
SKU	Stock Keeping Unit. Identificador único de un producto o prestación específica dentro del catálogo negociado con un proveedor.
Catálogo negociado	Subconjunto de SKUs y precios que un proveedor tiene autorizados y vigentes según su contrato con la cadena de retail.
Idempotency-Key	Encabezado HTTP que identifica de forma única un intento de confirmación de orden, usado para evitar procesar dos veces la misma solicitud ante reintentos de red.
Circuit Breaker	Patrón de resiliencia que corta temporalmente las llamadas hacia una dependencia externa que está fallando, para evitar el agotamiento de recursos propios (thread exhaustion).
Bulkhead	Patrón de resiliencia que aísla el pool de hilos/conexiones usado para una dependencia específica, para que su falla no consuma los recursos del resto del sistema.
Patron Outbox	Técnica que guarda el evento a publicar en la misma transacción de base de datos que el cambio de negocio, y un proceso separado (worker) lo envía luego al broker, evitando perder eventos si el broker falla.

Término	Definición
Deriva de configuración	Diferencia entre el estado deseado de un recurso y su estado real desplegado, que aparece cuando un cambio no queda registrado ni controlado.
SPOF	Single Point of Failure (punto único de falla). Componente cuya caída detiene una función crítica del sistema completo porque no existe redundancia ni degradación controlada.
Cuello de botella	Componente que no detiene el sistema pero limita su capacidad bajo carga alta, generando contención, colas o latencia creciente sin llegar a una caída total.
faults.yaml	Archivo de configuración recargable en caliente que define qué fallas debe inyectar el Motor de Fallas (latencia, error, caída) sobre un componente, sin necesidad de desplegar la aplicación.
RED / USE	Metodologías de métricas de observabilidad. RED (Rate, Errors, Duration) para servicios; USE (Utilization, Saturation, Errors) para recursos como CPU, memoria o pools de conexión.
ADR	Architecture Decisión Record. Documento corto que deja constancia de una decisión de arquitectura, sus alternativas consideradas y sus consecuencias.

2. A. Alcance

2.1 Dentro del alcance (in-scope)

- Implementación del monolito modular con los 4 módulos funcionales: proveedores, catálogo, órdenes, logística, con un esquema de base de datos por módulo (sin JOIN entre esquemas).
- Endpoint transaccional POST /ordenes-compra/{id}/confirmación, con los 6 pasos del flujo de confirmación (sección 3).
- Integración con un Stub simulador de validación tributaria/crédito, con latencia y tasa de error configurables.
- Generación y publicación del evento Orden Confirmada mediante patrón Outbox.
- Réplica de lectura de PostgreSQL dedicada a las consultas analíticas OTIF/Fill Rate.
- Panel de observabilidad (trazas, métricas RED/USE) y simulación de fallas mediante faults.yaml con kill switch.
- Verificación automatizada de fronteras entre módulos en el pipeline de CI (ArchUnit/Modulith/Packwerk según el lenguaje elegido).

2.2 Fuera del alcance (out-of-scope)

Además de las exclusiones explícitas de la versión anterior, se nombran a continuación las exclusiones que antes quedaban implícitas o genericas:

- Pasarela de pagos en vivo o integraciones bancarias reales.

- Interfaz de usuario compleja (frontend SPA/móvil); el sistema se evalúa vía API y pruebas de carga con k6/Gatling.
- Integración con sistemas ERP o WMS de terceros: el inventario físico y la facturación se asumen resueltos por sistemas externos fuera del alcance del semestre.
- Módulo de facturación electrónica y su validación ante autoridades fiscales reales (se simula únicamente vía el Stub).
- Gestión de inventario físico dentro del CEDI (conteo, picking, packing): el sistema solo reserva la franja de descargue, no gestiona la operación logística interna del CEDI.
- Planeación y ejecución de la última milla (entrega al punto de venta final).
- Extracción de un módulo del monolito hacia un microservicio independiente: queda fuera de esta entrega y se evaluará con datos reales de contención en entregas futuras.

2.3 Supuestos

- La infraestructura correrá completamente en contenedores (Docker / Docker Compose), con despliegue mediante un único comando ejecutable.
- Las peticiones de confirmación de orden incluyen el encabezado Idempotency-Key generado por el cliente (proveedor).
- Se dispone de una carga de datos sintética representativa antes de ejecutar las pruebas de la Entrega 2; no se usarán datos productivos reales.
- El equipo cuenta con un entorno de contenedores local suficiente para levantar los 3 app servers, PostgreSQL primaria y réplica, Redis y el broker de mensajes de forma simultánea durante las pruebas de carga.

2.4 Restricciones del proyecto

Las restricciones se presentan ahora como una lista propia, separada de los supuestos:

- Uso obligatorio de un esquema por módulo en PostgreSQL (sin consultas SQL con JOIN entre esquemas).
- Verificación estricta de fronteras mediante herramientas en CI (ArchUnit en Java / Modulith / Packwerk en Ruby).
- Despliegue con un único comando ejecutable (docker compose up).
- Extracción permitida de exactamente un módulo hacia un servicio independiente en entregas posteriores, únicamente si la evidencia de contención (métricas RED/USE) lo justifica; no se permite dividir más de un módulo en esta fase del proyecto.

2.5 Criterio de terminación de este entregable

Este entregable de diseño se considera terminado cuando: (1) el documento declara explícitamente que queda dentro y fuera de alcance, con exclusiones nombradas y no genéricas; (2) supuestos y restricciones están enunciados por separado, uno a uno; (3) los RF y RNF son atómicos, numerados y trazables a los pasos del

endpoint y a los SPOF; (4) los tres niveles del diagrama C4 y el diagrama de arquitectura de referencia son coherentes entre sí y con las decisiones ADR; y (5) cada SPOF tiene un mecanismo de mitigación asociado y una clasificación de impacto.

3. B. Descripción del dominio del sistema

3.1 Flujo de confirmación de orden

El sistema procesa la interacción entre miles de proveedores y una gran cadena de retail. La operación central es la confirmación de una orden de compra mediante el endpoint POST /ordenes-compra/{id}/confirmación, que recorre seis pasos:

- 1. Validar Proveedor y Contrato Vigente.
- 2. Verificar SKUs del Catálogo Negociado.
- 3. Reservar Franja CEDI (recurso escaso, con bloqueo pesimista).
- 4. Consulta Tributaria y de Crédito (dependencia externa lenta, timeout 1.5 s).
- 5. Confirmar Orden respetando la Idempotency-Key.
- 6. Publicar el evento OrdenConfirmada (patrón Outbox).

3.2 Actores y stakeholders

Actor	Necesidad o interés	Criticidad para el sistema
Proveedor B2B	Confirmar órdenes de compra con agilidad y asegurar su franja de entrega, sin sobreventas ni rechazos injustificados.	Alta: es quien inicia la transacción crítica del sistema.
Operador Logístico (CEDI)	Controlar la capacidad física de descargue por hora/día y evitar duplicación de citas en la franja.	Alta: su recurso (franja) es el cuello de botella físico del negocio.
Sistema Tributario / Financiero (externo)	Validar la situación fiscal y el cupo de crédito del proveedor antes de aceptar el compromiso.	Media: no es un usuario humano, pero condiciona la confirmación y es la dependencia más frágil.
Analista de Retail	Consultar en casi tiempo real el nivel de servicio (OTIF/Fill Rate) sin afectar la operación transaccional.	Media: su carga de lectura no debe degradar las escrituras.

3.3 Modelo de entidades y relaciones

Se presenta el modelo de entidades con sus atributos principales y la cardinalidad de sus relaciones. Este modelo es la base para el esquema por módulo declarado en las restricciones y para el diagrama de componentes.




Figura 1. Modelo de entidades y relaciones del dominio de confirmación de órdenes.

3.4 Ciclo de vida de la orden de compra

El estado de una Orden Compra evoluciona según el resultado de cada paso del flujo de confirmación. Una orden puede rechazarse en cualquiera de las primeras cuatro validaciones, y solo se libera la franja reservada si el rechazo ocurre después de haberla reservado (paso 3 en adelante).




Figura 2. Diagrama de estados de la orden de compra.

3.5 Justificación de la partición en los cuatro módulos

La partición en los cuatro módulos (proveedores, catálogo, órdenes, logística) no es arbitraria: cada módulo corresponde a un límite de propiedad de datos y de tasa de cambio distinta dentro del dominio. Proveedores y Catálogo cambian con baja frecuencia (altas/renovaciones de contrato, actualización de precios negociados) y son consultados, no escritos, durante la confirmación. Órdenes concentra el estado transaccional de alta escritura y es el único módulo que necesita garantías fuertes de independencia y consistencia. Logística aísla el recurso físico escaso (franja CEDI) porque su patrón de acceso es de alta contención concurrente, muy distinto al de los otros tres módulos, y es el candidato más probable a extraerse como servicio independiente si la evidencia de contención lo justifica. Esta separación también refleja los límites naturales de las reglas de

negocio: un cambio en la política de crédito de un proveedor no debería requerir tocar el código de reserva de franjas, y viceversa.

3.6 Reglas de negocio de la confirmación

- Una orden sólo puede confirmarse si el proveedor tiene un contrato vigente al momento de la solicitud (RF01).
- Todos los SKU de la orden deben pertenecer al catálogo negociado vigente del proveedor; un solo SKU fuera de catálogo rechaza la orden completa (RF02).
- Una franja CEDI no puede asignarse a más órdenes que su capacidad máxima; la reserva es exclusiva y no reversible una vez confirmada (RF03, RNF01).
- La validación tributaria/de crédito tiene un timeout máximo de 1.5 segundos; superado ese tiempo, la orden se rechaza y la franja reservada se libera automáticamente (RF04, RNF04).
- Una misma Idempotency-Key nunca debe producir dos órdenes confirmadas ni dos eventos OrdenConfirmada distintos (RF05, RNF 09).
- El evento OrdenConfirmada debe emitirse si y sólo si la orden quedó confirmada en base de datos, sin pérdida ni duplicación (RF06).

3.7 Tensiones del dominio

Tensión	Descripción	Consecuencia física/negocio
Recurso escaso y concurrente	Reserva de franjas de descargue en el CEDI. Si dos proveedores intentan reservar la última cita disponible al mismo tiempo, el sistema no puede sobrevivir ni compensar después.	Colas de camiones en el CEDI y reprogramaciones que rompen el compromiso de entrega.
Dependencia externa lenta	La validación tributaria y de crédito es intermitente y tiene latencia o timeouts propios; es la palanca principal de fallas en cascada.	Agotamiento de hilos/conexiones (thread exhaustion) y caída del throughput general del sistema.
Lectura analítica pesada	Consultas de OTIF y Fill Rate sobre 24 meses de historial que compiten directamente con las escrituras transaccionales.	Degradación de la latencia de confirmación de órdenes si comparten el mismo motor de base de datos sin aislamiento.

4. C. Requisitos funcionales y no funcionales

4.1 Requisitos funcionales (RF)

Cada RF cubre exactamente uno de los seis pasos del flujo de confirmación, de forma atómica y verificable de manera independiente.

ID	Requisito / escenario	Atributo	Métrica	Umbral objetivo	Metodo de verificacion
RF01	Ante una solicitud de confirmación, el sistema debe validar que el proveedor tenga un contrato vigente antes de continuar el flujo.	Correctitud funcional	% de solicitudes con contrato invalido correctamente rechazadas	100% en el set de prueba	Prueba unitaria + prueba de contrato con casos vigente/vencido /inexistente
RF02	Ante una solicitud de confirmación, el sistema debe verificar que todos los SKU de la orden pertenezcan al catálogo negociado vigente del proveedor.	Correctitud funcional	% de órdenes con SKU no negociado correctamente rechazadas	100% en el set de prueba	Prueba de integración con catálogo cargado
RF03	Ante una solicitud con contrato y catálogo válidos, el sistema debe reservar de forma exclusiva una franja CEDI, sin permitir sobreasignación.	Correctitud funcional / concurrencia	% de reservas concurrentes sin sobreventa	100% bajo prueba de concurrencia (N hilos, 1 franja)	Prueba de carga dirigida: N solicitudes simultáneas por la última franja disponible
RF04	Ante una franja reservada, el sistema debe consultar el estado tributario y de crédito del proveedor antes de confirmar.	Correctitud funcional / resiliencia	% de llamadas que respetan el timeout de 1.5 s	100%	Prueba con Stub configurado a latencia > 1.5 s via faults.yaml
RF05	Ante una solicitud repetida con la misma Idempotency-Key, el sistema debe devolver el resultado de la confirmación original sin reprocesar ni duplicar efectos.	Correctitud funcional / idempotencia	% de reintentos que generan una segunda orden o un segundo evento	0%	Prueba de reintento: enviar la misma petición 5 veces en paralelo
RF06	Ante una orden confirmada, el sistema debe publicar el evento Orden Confirmada de forma asíncrona usando el patrón Outbox.	Correctitud funcional / consistencia	% de órdenes confirmadas cuyo evento se publica eventualmente	100% (sin perdida, con reintento)	Prueba de caos: derribar el broker tras confirmar y verificar publicación al restaurar

ID	Requisito / escenario	Atributo	Métrica	Umbral objetivo	Metodo de verificacion
RF07	El sistema debe exponer endpoints de consulta de OTIF y Fill Rate acumulado sobre 24 meses de historial, resueltos contra la réplica de lectura.	Correctitud funcional / aislamiento de carga	% de consultas resueltas contra la replica (no contra la primaria)	100%	Inspección de plan de ejecución / logs de conexión por rol
RF08	El sistema debe permitir configurar, sin redesplicue, la latencia y la tasa de error inyectadas sobre el Stub tributario y sobre los app servers mediante faults.yaml.	Configurabilidad	Tiempo entre cambio de faults.yaml y efecto observable	<= 5 s (recarga en caliente)	Prueba manual: modificar faults.yaml y medir el cambio en latencia/errores reportados

4.2 Requisitos no funcionales (RNF)

Se agregan los RNF que el entregable anterior no declaraba (sesgo, presupuesto de error, SLO analítico, modularidad, reproducibilidad, configurabilidad de fallas) y se hacen medibles los que antes no lo eran.

ID	Atributo de calidad	Métrica	Umbral objetivo	Metodo de verificacion
RNF01	Concurrencia y aislamiento	% de reservas de franja sin lecturas sucias ni condiciones de carrera bajo 50 solicitudes concurrentes por la misma franja	0 sobreasignaciones	Prueba de carga dirigida con SELECT FOR UPDATE o lock distribuido; verificación del conteo final de cupos
RNF02	Volumetría mínima	Registros cargados en la base de prueba	100.000 proveedores; 10.000-15.000 contratos vigentes; hasta 400.000 SKU; 500.000 órdenes; >= 500.000 eventos de auditoría/outbox acumulados	Script de carga de datos con conteo posterior por tabla

ID	Atributo de calidad	Métrica	Umbral objetivo	Metodo de verificacion
RNF03	Distribución no uniforme de la carga (sesgo)	% de tráfico concentrado en el 5% de proveedores más activos, y % de órdenes en las 4 horas pico del día	5% de proveedores generan al menos 40% del tráfico; 60% de las órdenes se concentran en 4 franjas horarias pico (estacionalidad)	Inspección del generador de carga k6/Gatling y del script de datos sintéticos; auditoría de que la distribución no es uniforme
RNF04	Latencia operativa (declarada con carga)	p95 de latencia del endpoint de confirmación, bajo 200 rps sostenidos durante 10 minutos	p95 < 400 ms; tasa de error < 1%	Prueba de carga con k6/Gatling, reporte p50/p95/p99 y tasa de error en Grafana
RNF05	Presupuesto de error (error budget)	% de solicitudes de confirmación que pueden fallar en una ventana de 30 días sin incumplir el SLO acordado	Presupuesto de error <= 0.5% del total de solicitudes en 30 días (equivalente a un SLO de disponibilidad de 99.5% para el endpoint de confirmación)	Cálculo mensual sobre métricas RED de Prometheus (tasa de error acumulada vs presupuesto)
RNF06	SLO de la consulta analítica (latencia y frescura)	p95 de latencia de /otif y /fill-rate; y lag de replicación tolerado entre primaria y réplica	p95 < 800 ms; lag de replicación <= 5 minutos	Prueba de carga sobre endpoints analíticos + monitoreo de replication lag en Postgres
RNF07	Tolerancia a fallas de la dependencia externa	Tiempo máximo que una llamada al Stub puede bloquear un hilo de la aplicación	<= 1.5 s por llamada (Circuit Breaker + Bulkhead); el colapso del Stub no debe agotar el pool principal	Prueba de caos: Stub en modo latencia alta/caído via faults.yaml, medir hilos disponibles del pool principal
RNF08	Modularidad y propiedad de datos por módulo	% de verificaciones de frontera entre módulos que pasan en el pipeline de CI (ArchUnit/Modulith/Packwerk)	100% de las reglas de frontera declaradas deben pasar antes de mergear (0 violaciones permitidas)	Ejecución del pipeline de CI con el chequeo de arquitectura como gate obligatorio

ID	Atributo de calidad	Métrica	Umbral objetivo	Metodo de verificacion
RNF09	Consistencia: cero sobreasignación y cero confirmaciones duplicadas	N.o de franjas sobre asignadas y N.o de órdenes duplicadas por reintento de Idempotency-Key, sobre el total de pruebas	0 en ambos casos	Prueba de concurrencia (RNF01) + prueba de reintento (RF05) combinadas
RNF10	Reproducibilidad	Diferencia entre dos ejecuciones de carga con la misma configuración y semilla de datos sintéticos	Variación de p95 <= 10% entre corridas repetidas con la misma semilla	Dos ejecuciones idénticas del generador de carga con semilla fija, comparación de reportes

4.3 Volumetría de referencia (detalle de RNF02)

Entidad	Volumen mínimo exigido
Proveedores	100.000
Contratos vigentes	10.000 - 15.000
SKU (catálogo negociado)	hasta 400.000
Órdenes de compra almacenadas	500.000
Eventos de auditoría / outbox acumulados	>= 500.000

4.4 Distribución no uniforme de los datos sintéticos (detalle de RNF03)

Para evitar el antipatrón de datos uniformes (penalizado con -15% según el enunciado del curso), el generador de datos sintéticos y el generador de carga deben reproducir sesgo real del dominio:

- Sesgo de proveedores: el 5% de los proveedores más activos debe concentrar al menos el 40% del volumen de órdenes.
- Estacionalidad horaria: al menos el 60% de las órdenes debe concentrarse en 4 franjas horarias pico del día (por ejemplo, apertura de bodega y cierre de jornada).
- Popularidad de SKU: una distribución tipo Pareto (80/20) sobre la frecuencia de SKU solicitados, en vez de una selección aleatoria uniforme.

4.5 Presupuesto de error y SLO (detalle de RNF05 y RNF06)

El presupuesto de error formaliza cuanta falla es aceptable sin incumplir el compromiso de servicio, en vez de exigir cero errores:

- Endpoint de confirmación: SLO de disponibilidad de 99.5% en ventanas de 30 días -> presupuesto de error de 0.5% de las solicitudes.

- Endpoints analíticos (OTIF/Fill Rate): p95 < 800 ms y lag de replicación tolerado <= 5 minutos; una consulta que exceda ese lag debe declarar la antigüedad del dato en la respuesta, no fallar.

4.6 Matriz de trazabilidad RF - RNF - Puntos de falla

Esta matriz conecta cada requisito funcional con los requisitos no funcionales que lo acotan y con el punto único de falla que motiva esa exigencia, ausente en la versión anterior del documento.

RF	RNF relacionados	SPOF relacionado	Relación
RF01	RNF08 (modularidad, módulo Proveedores)	-	Valida el límite del módulo Proveedores sobre datos de Contrato.
RF02	RNF08 (modularidad, modulo Catalogo)	-	Valida el límite del módulo Catálogo.
RF03	RNF01, RNF09	SPOF-2 (contención en reserva de franja)	El requisito de exclusividad es la contramedida funcional al SPOF-2.
RF04	RNF04, RNF05, RNF07	SPOF-3 (Stub tributario / thread exhaustion)	El timeout y el Circuit Breaker mitigan directamente el SPOF-3.
RF05	RNF09, RNF10	-	La idempotencia sostiene la reproducibilidad de las pruebas de carga.
RF06	RNF05	SPOF-4 (broker de mensajes)	El patrón Outbox (ADR-03) es la mitigación directa del SPOF-4.
RF07	RNF06	SPOF-1 (contención OLTP/OLAP en PostgreSQL primaria)	La réplica de lectura (ADR-02) es la mitigación directa del SPOF-1.
RF08	RNF05, RNF07	SPOF-3	Permite reproducir y verificar la resiliencia sin redespregar.

5. D. Puntos únicos de falla (SPOF) y decisiones de arquitectura (ADR)

5.1 Inventario de puntos de falla, cuellos de botella y degradaciones

Se distingue explícitamente un punto único de falla (SPOF, detiene una función crítica sin redundancia) de un cuello de botella (limita capacidad bajo carga sin detener el sistema) y de una degradación controlada (pérdida de calidad de servicio aceptable y esperada). También se incorporan los componentes de la propia arquitectura de referencia que la versión anterior no analizaba: API Gateway, Balanceador, Redis y la Réplica de lectura.

ID	Componente	Tipo y descripción	Impacto / Prob. / Radio	Familia	Mitigación (ADR)
SPOF-1	PostgreSQL Primaria (escritura) y su pool de conexiones	Punto único de falla real: si la primaria cae o el pool se agota, toda la confirmación de órdenes colapsa (no hay redundancia de escritura).	Alto / Media / Total (bloquea el 100% de las confirmaciones)	B - Fallas de infraestructura de datos	ADR-02 (replica de lectura separa OLAP) + PgBouncer (pool gestionado); redundancia de escritura queda fuera del alcance del semestre
SPOF-2	Reserva concurrente de franja CEDI	No es un SPOF puro sino un cuello de botella de contención: un cerrojo mal diseñado no detiene el sistema completo, pero puede paralizar los hilos que compiten por la misma fila, degradando la capacidad de confirmar cualquier orden.	Alto / Alta / Parcial (afecta las órdenes concurrentes sobre la misma franja, no todo el sistema)	C - Fallas de software/concurrencia	ADR-05 (bloqueo pesimista acotado en el tiempo o cerrojo distribuido en Redis con TTL)
SPOF-3	Stub externo de validación tributaria (dependencia lenta)	Punto único de falla por dependencia externa: sus latencias altas consumen los pools de hilos del backend (thread exhaustion) si no hay aislamiento, degradando todo el sistema aunque el Stub mismo no sea parte de la infraestructura propia.	Alto / Alta / Total si no hay Circuit Breaker (arrastra a toda la aplicación)	D - Fallas de dependencias externas	ADR-04 (Circuit Breaker + Bulkhead aislado, timeout 1.5 s)
SPOF-4	Broker de mensajes (Kafka/RabbitMQ)	Punto único de falla para la entrega de eventos: si el broker se interrumpe, se pueden perder eventos de confirmación si no existe un patrón Outbox transaccional.	Medio / Media / Parcial (no bloquea la confirmación, pero rompe la consistencia de eventos aguas abajo)	B - Fallas de infraestructura de mensajería	ADR-03 (Transactional Outbox)
SPOF-5	API Gateway / Balanceador de carga	Punto único de falla de entrada: si se despliega una única instancia del Gateway o del	Alto / Baja (componentes estándar, pero con bajo esfuerzo)	A - Fallas de infraestructura de	Desplegar Gateway y balanceador en modo activo-pasivo o con múltiples réplicas

ID	Componente	Tipo y descripción	Impacto / Prob. / Radio	Familia	Mitigación (ADR)
	(instancia única de cada uno en el diagrama)	balanceador, su caída bloquea el 100% del tráfico aunque los app servers estén sanos. No analizado en la versión anterior del documento.	de redundancia) / Total	red/entrada	detrás de un DNS/VIP; queda como trabajo futuro si el semestre no alcanza
SPOF-6	Redis (cache)	No es SPOF sino degradación controlada esperada: si Redis cae, el sistema debe seguir funcionando leyendo directo de PostgreSQL (cache-aside), a costa de mayor latencia y carga sobre la primaria/réplica. Se documenta para evitar que el equipo lo trate como bloqueante.	Bajo / Media / Parcial (solo degrada latencia, no bloquea)	C - Fallas de software/cache	Cache-aside con fallback a base de datos; alerta si la tasa de miss supera un umbral
SPOF-7	Réplica de lectura de PostgreSQL	Cuello de botella, no SPOF: si la réplica cae o se atrasa, las consultas OTIF pueden degradarse o servirse con datos desactualizados, pero no debe bloquear la confirmación de órdenes (que usa la primaria).	Medio / Baja / Parcial (afecta solo lecturas analíticas)	B - Fallas de infraestructura de datos	Alertar por lag de replicación (RNF06) y degradar a 'datos con antigüedad X' en vez de fallar

Nota sobre la clasificación por familias: se adopta una taxonomía de cuatro familias (A: infraestructura de red/entrada, B: infraestructura de cómputo/datos/mensajería, C: software y concurrencia propia, D: dependencias externas) como supuesto de trabajo del equipo, a falta de que el catálogo A/B/C/D específico del curso haya sido publicado al momento de este entregable; se ajustará la etiqueta de cada SPOF si el catálogo oficial define categorías distintas.

5.2 Decisiones de arquitectura (ADR)

Cada ADR ahora declara la alternativa que se consideró y se descartó, con su razón, y las consecuencias o trade-offs de la decisión tomada -no solo el beneficio-, incluyendo el caso de ADR-05, cuyo propio trade-off es el mecanismo que genera el SPOF-2 que busca mitigar.

ADR	Título	Decisión	Justificación (beneficio)	Alternativas descartadas	Consecuencias / trade-offs
ADR-01	Arquitectura inicial de monolito modular	Adoptar un monolito con 4 módulos bien delimitados y esquemas de BD separados.	Reduce la complejidad operativa inicial y asegura que la separación en microservicios sea guiada por métricas reales.	Alternativa descartada: microservicios desde el inicio (Cluster API/K8s completo). Se descarta por el costo operativo y de coordinación que no se justifica sin evidencia de contención real en un semestre.	El monolito acopla el ciclo de despliegue de los 4 módulos: un cambio en Catálogo obliga a redespregar todo el sistema, lo que puede aumentar el riesgo operativo frente a microservicios independientes.
ADR-02	Separación de lectura y escritura (CQRS ligero)	Implementar una réplica de lectura en PostgreSQL dedicada a analítica (OTIF).	Evita que las consultas pesadas sobre 24 meses bloqueen las escrituras transaccionales de órdenes.	Alternativa descartada: usar un almacén analítico separado (data warehouse/OLAP dedicado). Se descarta por el esfuerzo de ETL adicional, fuera del alcance de un semestre.	La réplica introduce lag de replicación (RNF06): los indicadores OTIF pueden mostrar datos con hasta 5 minutos de antigüedad, lo que debe comunicarse al Analista de Retail.
ADR-03	Patrón Transaccional Outbox	Guardar el evento OrdenConfirmada en la misma transacción de la BD y un worker lo envía al broker.	Previene la pérdida de eventos cuando el broker de mensajes presenta caídas o latencia.	Alternativa descartada: publicar el evento directamente desde el service tras el commit (dual write). Se descarta porque no garantiza la atomicidad entre la escritura en BD y la publicación.	Agrega latencia de publicación (el evento no es instantáneo, depende del polling/CDC del worker) y una tabla adicional que debe purgarse periódicamente.
ADR-04	Resiliencia para la dependencia externa	Implementar Circuit Breaker (Resilience4j/Gobreaker) y Bulkhead aislado para el Stub Tributario.	Aísla los fallos de la dependencia lenta para evitar la inanición del pool principal de peticiones.	Alternativa descartada: reintentos simples con backoff sin Circuit Breaker. Se descarta porque bajo una caída sostenida del Stub, los reintentos agravarían el thread exhaustion en vez de evitarlo.	El Circuit Breaker puede rechazar solicitudes legítimas mientras está abierto (falsos negativos), lo que exige comunicar al proveedor un estado 'pendiente de validación' en vez de un rechazo definitivo.
ADR-05	Control concurrente en la reserva	Utilizar Pessimistic Locking (SELECT FOR UPDATE) acotado en el	Garantiza cero sobreventas en la asignación física de citas en el CEDI.	Alternativa descartada: Optimistic Locking (versión/timestamp con reintento). Se descarta como opción inicial	El bloqueo pesimista introduce exactamente el tipo de contención que advierte el SPOF-2: bajo alta concurrencia sobre la

ADR	Título	Decisión	Justificación (beneficio)	Alternativas descartadas	Consecuencias / trade-offs
	de franjas CEDI	tiempo, con opción de migrar a cerrojos distribuidos en Redis si la contención lo exige.		porque bajo alta contención sobre una franja popular generaría una tasa alta de reintentos fallidos, empeorando la experiencia del proveedor; queda como alternativa a evaluar en la Entrega 2 con datos reales.	misma franja, los hilos que esperan el lock pueden acumularse. Se mitiga acotando el tiempo de espera del lock y devolviendo error de 'franja en disputa' en vez de bloquear indefinidamente.

6. E. Diagrama C4 (Context, Container, Component)

Leyenda de notación: las cajas azul oscuro representan personas, azul medio representa el sistema o sus contenedores, gris representa sistemas externos, verde representa almacenes de datos, morado representa mensajería/eventos, y dorado representa observabilidad e inyección de fallas. El texto entre corchetes indica el tipo C4 y, cuando aplica, la tecnología concreta. Las flechas punteadas representan relaciones de soporte (observabilidad, verificación de CI, inyección de fallas); las flechas sólidas representan flujo de datos o llamadas.

6.1 Nivel 1 - Contexto




Figura 3. Diagrama de contexto (Nivel 1) con los tres actores humanos y el sistema externo.

6.2 Nivel 2 - Contenedores




Figura 4. Diagrama de contenedores (Nivel 2).

6.3 Nivel 3 - Componentes




Figura 5. Diagrama de componentes (Nivel 3), con los pasos del flujo numerados y las fronteras de esquema.

7. F. Diagrama de arquitectura de referencia de la solución




Figura 6. Diagrama de arquitectura de referencia de la solución.

7.1 Componentes desplegables

Zona	Componentes
Traffic Ingress	k6/Gatling (generador de carga con RPS objetivo declarado); API Gateway (rate limiting, autenticacion, inyeccion de trace-id); Balanceador de carga (HAProxy/Nginx, least-conn); Pipeline de CI (ArchUnit/Modulith/Packwerk, verifica fronteras entre módulos antes de cada despliegue).
Application Layer	Cluster de 3 instancias del backend monolito modular (app.1, app.2, app.3).
Persistence & Messaging	PostgreSQL primaria (fuente de verdad, pool PgBouncer); réplica de lectura dedicada a OTIF/Fill Rate (lag tolerado ≤ 5 min); Redis (cache-aside con invalidación activa on-write, PostgreSQL es la fuente de verdad); Kafka/RabbitMQ (broker); Outbox Publisher (worker del patron Outbox).
Dependencia externa	Stub Tributario/Crédito, con latencia y tasa de error configurables vía faults.yaml (timeout de 1.5 s desde la aplicación, con Circuit Breaker y Bulkhead).
Observabilidad & Chaos	OTel Collector, Prometheus (métricas RED/USE), Jaeger (trazas), Grafana (tablero p50/p95/p99), Motor de Fallas (faults.yaml recargable, kill switch por endpoint admin).